

多模态融合与集成投票的对话轮次交互建模

第 11 届信也科技杯 · Turn-Taking 复赛技术报告

队名：没想好 日期：2026 年 6 月 23 日

摘要

本方案面向多方言中文对话的轮次交互 (Turn-Taking) 建模：给定过去 ≤ 30 s 的双声道对话 (音频、ASR 文本、历史 chunk 标签)，预测未来 2 s (25×80 ms chunk) 内是否出现延续 (C)、静音 (NA)、打断 (I)、附和 (BC)、话权转移 (T) 五类事件。我们构建了 **音频/文本/历史标签/手工统计** 四路模态的多模态模型，以**低秩张量融合 + 自适应门控聚合**，多标签 sigmoid 输出；训练采用 focal 损失、按类上限的正样本加权、标签平滑与**权重 EMA**；推理阶段对 valid 上最优的 **Top-5** 模型逐标签用各自最优阈值二值化后做**多数投票**，以提升在私域测试集 (上下文 (0,30] s 动态变长) 上的鲁棒性。

1 任务与整体流程

轮次交互的核心是判断 AI「何时开口、何时收声」。我们将其建模为**事件级多标签二分类**：对未来 2 s 窗口内 5 类标签 $\{C, NA, I, BC, T\}$ 分别预测「是否出现」。整体流程见图 1，满足**因果约束**——仅使用上下文，不读取未来音频或未来标签。

2 数据构造

训练数据为整通双声道对话。以 80 ms 为一个 chunk，沿对话以步长 `stride` 滑窗切样本：取结束位置前 `context_chunks=375` (30 s) 作为上下文，其后 `target_chunks=25` (2 s) 作为预测窗口；标签向量 $y_k = \mathbb{I}[\text{未来窗口内出现第 } k \text{ 类}]$ 。为贴合私域测试集上下文 (0,30] s 的**动态变长**特性，训练时以概率 `context_prob` 随机将上下文长度采样到 [125,375] chunk，不足处以 NA(=4) 左侧补齐；测试时同样把变长上下文归一化到定长 375 (截取末段、不足补 NA)，保证 batch 内长度统一。

3 多模态模型

3.1 音频编码器

采用 **Whisper-large-v3** 的 encoder：整体冻结、仅解冻**最后 2 层**做任务自适应。为省显存，冻结前缀在 `no_grad` 下前向、仅尾部可训练层建图。在时间轴上只对**尾部** (`tail_ratio=0.25`) 做注意力池化，聚焦临近预测窗口的声学线索，再投影到 512 维。

3.2 文本编码器

ASR 文本按说话人加 [SPK1]/[SPK2] 标记拼接，送入冻结的 **Qwen3-0.6B**；对序列尾部做带 mask 的注意力池化 (近因 utterance 更重要)。tokenizer 采用**左侧截断/左侧补齐**，保留最近上下文。

3.3 历史标签编码与手工特征

历史 chunk 标签经 Embedding 后走**双分支 CNN**：尾部分支 (最近 `tail_k=75` chunk) 做细粒度卷积 + 展平，全局分支做卷积 + 注意力池化，拼接得到标签时序表征。同时计算**手工统计特征**：近 25/50/100 窗口的标签分布、到最近事件/话权转移的距离、标签转移概率、指数/线性时间衰减分布、均值方差变化率、话轮间隔等，投影为 64 维，为模型注入强先验。

3.4 低秩张量融合与自适应门控

四路模态 $\{a, t, c, h\}$ 先做**低秩张量融合** (rank=64) 以紧凑地建模高阶交互：

$$z_{\text{int}} = \left(\sum_{r=1}^R \odot_m \tilde{x}_m W_m^{(r)} \right) \odot w_f + b,$$

其中 $\tilde{x}_m = [1; x_m]$ 。再对每路做投影并由**门控网络**输出 4 个 [0,1] 权重，按门控加权后与 z_{int} 拼接、投影到 320 维融合表征，使模型可按样本自适应地决定信任哪个模态。

3.5 预测头与损失

融合表征经线性头输出 5 维 logits，sigmoid 后与标签做 BCE。针对类别不均衡，采用 **focal** 调制 ($\gamma=2$) + **按类上限正样本加权** (cap=8) + 标签平滑 (0.05)：

$$\mathcal{L} = \frac{1}{K} \sum_k \alpha_k (1 - p_{t,k})^\gamma \text{BCE}(p_k, \tilde{y}_k).$$

4 训练策略

4×L20 四卡 DDP, 等效批 512; 峰值 lr 1.2×10^{-4} , warmup 0.03, cosine 衰减, weight decay 0.03, 梯度裁剪 1.0, AMP 混合精度。引入**权重 EMA** (decay 0.999)：评估与保存集成成员时使用 EMA 权重，有效闭合大批量带来的泛化间隙。按 `valid best_f1` 选优并早停 (patience 15)。

5 集成与阈值

训练过程中按 `valid best_f1` 排名保留 **Top-5** 成员；每个成员在 valid 上**逐标签搜索**使 F1 最大的阈值，连同成员清单写入 `ensemble_manifest.json`。推理时**逐成**




图 1: 从原始数据到最终结果的整体流程: 数据切分 → 多模态编码 → 融合 → 多标签预测 → 集成投票 → 输出。

员 (同一时刻 GPU 上仅驻留一个模型, 显存峰值 = 单模型) 用各自最优阈值把每个标签二值化, 再做**逐标签多数投票**: 得票 > 半数 (5 个成员即 ≥ 3 票) 判为 1。成员 checkpoint 为「瘦身」格式 (仅存可训练参数), 推理时从本地预训练骨干以 `strict=False` 叠加还原, 节省体积。

6 复现说明

代码结构与运行命令 (详见 README.md):

- **训练**: `bash train.sh` (4 卡 DDP, 产出 Top-5 成员与 manifest)。
- **推理**: `bash run.sh` (入口) , 读 `/xydata` → 集成投票 → 写 `/app/submit/submit.csv` (列: `segment_id,c,na,i,bc,t`)。
- **环境**: `pytorch/pytorch:2.5.1-cuda12.4`, `transformers 4.57.x`, 骨干权重离线本地加载。

单成员参数量约 1.2B (Whisper encoder + Qwen3-0.6B + 轻量融合头), 推理一次仅载入一个成员, 满足参数量与显存约束。